

Universidad Internacional de la Rioja (UNIR)

**Escuela Superior de Ingeniería y
Tecnología**

Master universitario en Inteligencia Artificial

Diseño de un asistente institucional, RAG e integración de herramientas

Trabajo Fin de Máster

Presentado por: Nuria Iglesias Traviesa

Director: David Jimenez Cabello

Ciudad: Valencia

Fecha: 22/04/2026

Índice general

1. Introducción	1
1.1. Motivación	1
1.2. Planteamiento del trabajo	2
1.3. Estructura del trabajo	3
2. Contexto y estado del arte	5
2.1. Contexto	5
2.2. Estado del arte	6
2.2.1. Agentes y orquestación	7
2.2.2. Uso de herramientas e integración de capacidades	7
2.2.3. RAG	8
2.2.4. Evaluación y mejora concreta del retrieval	9
2.2.5. Asistentes institucionales	10
2.3. Encaje de la propuesta	11
2.4. Conclusiones	12
3. Objetivos y Metodología	14
3.1. Objetivos Generales	14
3.2. Objetivos Específicos	14
3.3. Criterios de comprobación de los objetivos	15
3.4. Metodología del trabajo	16
3.4.1. Scrum	16
3.4.2. Roles	17
3.4.3. Artefactos	17
3.4.4. Eventos	17
3.4.5. Adaptación al proyecto	18
3.5. Riesgos y planes de contingencia	18

3.6. Planificación del trabajo	20
3.6.1. Sprint 1: análisis y definición del problema	20
3.6.2. Sprint 2: diseño de la arquitectura y preparación del entorno de trabajo	20
3.6.3. Sprint 3: implementación del <i>baseline</i> del asistente	20
3.6.4. Sprint 4: integración de la funcionalidad accionable	21
3.6.5. Sprint 5: implementación de la mejora del componente de recuperación de información	21
3.6.6. Sprint 6: diseño de la evaluación y comparación experimental	21
3.6.7. Sprint 7: Revisión final, análisis de resultados y redacción de la memoria	22
3.7. Recursos y costes	22
3.7.1. Recursos humanos	22
3.7.2. Recursos técnicos	23
3.7.3. Estimación de dedicación	23
3.7.4. Estimación de costes	24
4. Fundamentos tecnológicos	25
4.1. Tecnologías de desarrollo	25
4.1.1. Python	25
4.1.2. UI: Streamlit como opción preferente	25
4.1.3. Qdrant	26
4.2. Librerías utilizadas	26
4.2.1. Embeddings: BGE-M3	26
4.2.2. LLM: vLLM con modelo local cuantizado	27
4.2.3. Reranking: BGE Reranker	27
4.3. Funcionalidad accionable	27
4.3.1. Correos mockeados	27
4.4. Procesamiento documental e ingesta	27
5. Conclusiones y trabajo futuro	29
Bibliography	30
Appendices	33
Apéndice A. Fusce viverra lectus	34

Resumen

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Palabras clave: Modelos de lenguaje de gran tamaño, Retrieval-Augmented Generation, Recuperación híbrida, Reranking, Uso de herramientas, Asistente institucional

Abstract

Proin tincidunt enim nec fringilla euismod. Quisque id efficitur sapien. Sed hendrerit, nisl id efficitur elementum, arcu ex efficitur ipsum, sed auctor metus nibh id leo. Maecenas eu sem tortor. Etiam accumsan bibendum ante vitae auctor. Donec eget dolor gravida, tincidunt diam non, ornare orci. Pellentesque ornare blandit eros, sed maximus neque varius non.

Keywords: Large Language Models, Retrieval-Augmented Generation, Hybrid Retrieval, Reranking, Tool Use, Institutional Assistant

Índice de figuras

1. Diagrama de Gantt con la planificación temporal del trabajo.	22
---	----

Índice de Tablas

1.	Estimación de horas dedicadas al proyecto.	23
2.	Estimación orientativa de costes humanos del proyecto.	24

Capítulo 1

Introducción

En este primer capítulo se presenta el sistema de agentes con integración de herramientas orientadas a la realización de acciones útiles para el usuario, así como la propuesta de mejora del componente de recuperación de información. Asimismo, se describen la motivación y el contexto del trabajo, el planteamiento general de la solución, los objetivos a grandes rasgos y la estructura del documento.

1.1. Motivación

La motivación principal de este trabajo surge de la necesidad de explorar cómo diseñar un asistente institucional que combine consulta documental y capacidad de realizar acciones. Frente a enfoques centrados exclusivamente en la generación de respuestas, se parte de la idea de que un asistente útil en un entorno institucional debe ser capaz no solo de informar, sino también de ayudar a materializar el siguiente paso de manera controlada y supervisada por el ser humano.

Esta necesidad resulta especialmente visible en el ámbito universitario, donde parte de la información relevante para el estudiante se encuentra dispersa en normativas, páginas web, documentos administrativos o guías internas cuya consulta no siempre es sencilla. Cuestiones relacionadas con trámites, prácticas, horarios o becas pueden generar dudas incluso cuando la información existe, simplemente porque no resulta fácilmente accesible o comprensible. En este contexto, disponer de un asistente capaz de responder de forma clara, fundamentada y contextualizada puede suponer una mejora significativa en la experiencia del usuario, especialmente si se tiene en cuenta que muchas instituciones universitarias todavía no cuentan con herramientas conversacionales suficientemente útiles, especializadas o integradas para este tipo de consultas.

A ello se añade una segunda motivación de carácter investigador. En sistemas basados en *Retrieval-Augmented Generation* (RAG), la calidad de la recuperación documental condiciona directamente la calidad de las respuestas generadas. Por este motivo, resulta de interés analizar si una mejora concreta del componente de recuperación, basada en estrategias de recuperación híbrida y *reranking* (Nogueira y col., 2020a), puede traducirse en una mejora observable en las respuestas y en la utilidad general del asistente. De este modo, el trabajo no solo responde a una necesidad práctica de desarrollo, sino también a una pregunta aplicada de investigación sobre el impacto real de optimizar el *retrieval* en asistentes institucionales.

1.2. Planteamiento del trabajo

Se propone el desarrollo de un asistente conversacional institucional privado que permita consultar documentación interna, ofrecer respuestas fundamentadas y apoyar acciones útiles para el usuario dentro de un entorno controlado.

Esta propuesta no aspira únicamente a construir un sistema conversacional más, sino a desarrollar una solución capaz de combinar acceso a conocimiento documental, razonamiento sobre la información recuperada y apoyo operativo en tareas concretas. De este modo, el asistente no se limitará a responder preguntas en lenguaje natural, sino que estará orientado a ofrecer información precisa y trazable a partir de documentación institucional, así como a apoyar acciones supervisadas por el usuario cuando la consulta requiera una actuación posterior.

Esta propuesta toma forma mediante la incorporación de distintas capacidades complementarias articuladas en varios bloques principales. En primer lugar, se plantea una arquitectura modular basada en un agente orquestador, encargado de coordinar los distintos componentes del sistema y de gestionar de forma desacoplada las capacidades disponibles. Desde una perspectiva agéntica, la consulta del usuario se interpreta como una tarea que debe ser resuelta por un agente orquestador. Este agente será el encargado de decidir qué capacidades necesita activar en cada caso, pudiendo recurrir a distintas herramientas especializadas. Entre ellas se incluye una herramienta de recuperación documental sobre una base privada de documentos, encargada de localizar evidencia relevante para fundamentar la respuesta. Sobre dicha evidencia, el modelo de lenguaje genera una respuesta contextualizada y, cuando la tarea lo requiera, el orquestador podrá activar herramientas adicionales, como la generación de borradores de correo o el envío supervisado de mensajes.

Para evaluar el rendimiento de la propuesta, se definirá un conjunto de datos de prueba compuesto por documentación institucional y un conjunto de consultas representativas del dominio. Estas consultas cubrirán distintos escenarios de uso, incluyendo preguntas informativas,

consultas sobre procedimientos y peticiones orientadas a la generación de una acción posterior, como la redacción de un correo formal. Sobre este conjunto se comparará el comportamiento de un *baseline* basado en búsqueda semántica con una variante mejorada basada en búsqueda híbrida y *reranking*, considerando tanto métricas de recuperación como la fundamentación de las respuestas generadas y la utilidad de las salidas producidas.

El asistente no se limita a responder preguntas, sino que puede facilitar tareas útiles para el usuario, como la generación o el envío supervisado de correos electrónicos. Por último, el trabajo incluye una vertiente experimental centrada en la mejora del componente de recuperación de información, mediante la comparación entre un *baseline* inicial y una estrategia mejorada basada en recuperación híbrida y *reranking*.

1.3. Estructura del trabajo

La memoria se organiza en varios capítulos que permiten abordar de forma progresiva tanto la definición del problema y la planificación del trabajo como su fundamentación teórica, su desarrollo técnico y su validación experimental.

De forma más concreta, la estructura del documento es la siguiente:

- **Capítulo 1. Introducción.** Presenta el contexto y la motivación del trabajo, el planteamiento general de la solución y la organización de la memoria.
- **Capítulo 2. Contexto y estado del arte.** Revisa los antecedentes más relevantes sobre agentes basados en modelos de lenguaje, orquestación, uso de herramientas, sistemas de recuperación aumentada, mejora del *retrieval* y asistentes institucionales especializados.
- **Capítulo 3. Objetivos y metodología.** Define los objetivos generales y específicos del trabajo, los criterios de comprobación planteados, la metodología seguida, la planificación, los riesgos identificados y los recursos necesarios.
- **Capítulo 4. Diseño e implementación de la propuesta.** Describe la arquitectura general del asistente institucional, el papel del agente orquestador, el sistema de recuperación documental, la integración de herramientas accionables y las principales decisiones técnicas adoptadas durante el desarrollo del prototipo.
- **Capítulo 5. Evaluación experimental y discusión de resultados.** Presenta el conjunto de evaluación, el *baseline* de recuperación, la variante mejorada basada en búsqueda

híbrida y *reranking*, las métricas empleadas, los resultados obtenidos y su análisis en relación con los objetivos planteados y las limitaciones del sistema.

- **Capítulo 6. Conclusiones y trabajo futuro.** Resume las principales aportaciones del trabajo, valora el grado de cumplimiento de los objetivos planteados y expone posibles líneas de mejora o ampliación futura.

Capítulo 2

Contexto y estado del arte

En este capítulo se describe el contexto del trabajo y se revisa el estado del arte de las tecnologías y enfoques más relevantes para la propuesta. Además, se analiza el encaje de la solución planteada dentro de la literatura revisada y se exponen las principales conclusiones obtenidas.

2.1. Contexto

En los últimos años, el desarrollo de la inteligencia artificial generativa ha impulsado la aparición de agentes conversacionales cada vez más capaces de desenvolverse en escenarios reales. Una de las líneas más relevantes en esta evolución ha sido la incorporación de mecanismos de acceso a conocimiento externo, de modo que los modelos pueden consultar documentación, bases de datos y servicios externos para fundamentar mejor sus respuestas. En este contexto, los enfoques basados en *Retrieval-Augmented Generation* (RAG) (Lewis y col., 2020) han adquirido un papel central, al permitir combinar las capacidades generativas de los modelos con la recuperación de documentación relevante.

Al mismo tiempo, los modelos de lenguaje han dejado de concebirse únicamente como interfaces conversacionales y han pasado a integrarse en sistemas capaces de apoyar flujos de trabajo más amplios. Esta evolución resulta especialmente significativa en entornos institucionales, donde las consultas de los usuarios no siempre finalizan en una simple respuesta informativa, sino que suelen desembocar en una acción posterior, como la redacción de un correo o la realización de un trámite. En este tipo de contextos aparecen además exigencias adicionales, ya que el sistema debe operar sobre documentación interna, respetar restricciones de acceso a la información y ofrecer un mayor grado de control sobre su comportamiento.

2.2. Estado del arte

La literatura reciente ha explorado con especial interés las arquitecturas de agentes y los mecanismos de orquestación. En esta línea, ReAct (Yao y col., 2023) plantea una combinación entre razonamiento y acción, mientras que trabajos como AgentVerse (Chen y col., 2024), MetaGPT (Hong y col., 2024) y AutoGen (Wu y col., 2024) avanzan hacia esquemas de colaboración y coordinación entre agentes. Más recientemente, Dang et al. (Dang y col., 2025) abordan la orquestación multiagente como un mecanismo dinámico de coordinación. De forma complementaria, otra línea de trabajo relevante se centra en el uso de herramientas y APIs externas por parte de modelos de lenguaje. Toolformer (Schick y col., 2023) introduce la capacidad de aprender cuándo y cómo invocar herramientas, mientras que Gorilla (Patil y col., 2024) y ToolLLM (Qin y col., 2024) exploran la conexión de modelos de lenguaje con APIs reales. En esta misma dirección, API-Bank (Li y col., 2023) propone un benchmark específico para evaluar sistemas aumentados con herramientas. Asimismo, los sistemas de Retrieval-Augmented Generation fueron introducidos por Lewis et al. (Lewis y col., 2020) como un enfoque para combinar modelos generativos con recuperación de conocimiento externo. Trabajos posteriores como REPLUG (Shi y col., 2024), Self-RAG (Asai y col., 2024) y Adaptive-RAG (Jeong y col., 2024) han profundizado en distintas formas de integrar, controlar o adaptar el proceso de recuperación. Finalmente, también se han propuesto asistentes especializados para dominios institucionales, universitarios o cerrados. Marcel (Trientes y col., 2025) se orienta al soporte conversacional de estudiantes universitarios, URASys (Nguyen y col., 2025) aborda consultas ambiguas o no respondibles en contextos académicos, y HyPA-RAG (Kalra y col., 2025) aplica recuperación híbrida y adaptación de parámetros en un dominio especializado.

Estas líneas resultan especialmente relevantes porque la propuesta no se limita a diseñar un sistema conversacional genérico, sino un asistente institucional con capacidad para consultar documentación interna, utilizar herramientas accionables y transformar una respuesta fundamentada en una actuación útil para el usuario. Además, el trabajo incorpora una contribución experimental específica centrada en la mejora del componente de recuperación de información mediante una estrategia de recuperación híbrida y *reranking*. Por ello, este estado del arte no solo revisa los fundamentos técnicos del sistema, sino también sitúa la propuesta en relación con soluciones institucionales existentes y con las principales líneas de mejora del retrieval.

2.2.1. Agentes y orquestación

Una de las líneas más influyentes en este ámbito es la que entiende al agente basado en modelos de lenguaje no como un simple generador de texto, sino como una entidad capaz de razonar, planificar y actuar sobre el entorno. En esta dirección, Yao et al. (Yao y col., 2023) proponen ReAct, un enfoque que combina trazas de razonamiento con acciones explícitas ejecutadas sobre fuentes externas o entornos interactivos. Para el contexto de este trabajo, ReAct resulta especialmente relevante porque introduce una base conceptual clara para el diseño de un agente orquestador que no solo responde, sino que decide qué hacer, qué consultar y en qué orden ejecutar cada paso.

Sobre esta idea inicial, la investigación posterior ha ampliado el foco desde agentes individuales hacia sistemas compuestos por múltiples agentes especializados, como AgentVerse (Chen y col., 2024), un marco de colaboración multiagente en el que distintos agentes cooperan para resolver tareas. Los resultados descritos por los autores muestran que, en determinados escenarios, un conjunto coordinado de agentes puede superar a un único agente generalista.

Hong et al. (Hong y col., 2024) proponen MetaGPT que frente a aproximaciones más informales, introduce una organización más estructurada del trabajo entre agentes, de forma que cada componente participa en una fase concreta del proceso y verifica resultados intermedios. Sugiere que la división explícita de responsabilidades puede reducir inconsistencias y facilitar la incorporación de nuevas capacidades sin rediseñar completamente el sistema.

Por su parte, Wu et al. (Wu y col., 2024) presentan AutoGen, uno de los elementos más destacables es que los agentes pueden operar en distintos modos, combinando modelos de lenguaje, intervención humana y uso de herramientas externas. Esta visión encaja con el enfoque de este proyecto, en el que se persigue una arquitectura en la que un agente orquestador coordine módulos y capacidades desacopladas dentro de un entorno controlado.

Más recientemente, Dang et al. (Dang y col., 2025) plantean un esquema centralizado en el que un orquestador dirige de forma adaptativa a los distintos agentes según el estado de la tarea. Aportan evidencias de que la orquestación debe entenderse como un mecanismo de coordinación capaz de reorganizar prioridades, seleccionar agentes adecuados y ajustar el flujo de ejecución en función del contexto.

2.2.2. Uso de herramientas e integración de capacidades

Una de las limitaciones más relevantes de los modelos de lenguaje es su dificultad para interactuar de forma fiable con recursos externos. Por este motivo, una línea de investigación cada vez más importante se centra en el *tool use*, entendido como la capacidad de un mo-

delo para decidir cuándo utilizar una herramienta y cómo incorporar el resultado obtenido a la respuesta final.

Uno de los trabajos de referencia en esta línea es Toolformer (Schick y col., 2023). Su contribución principal es demostrar que el modelo no solo puede ejecutar llamadas a APIs, sino también aprender a decidir en qué momento conviene hacerlo y qué argumentos debe pasar. Esta propuesta aporta una base conceptual sólida para entender la invocación de herramientas como una capacidad integrada dentro del comportamiento del agente.

Una contribución complementaria es ToolLLM, presentada por Qin et al. (Qin y col., 2024). En este caso, los autores proponen entrenar y evaluar modelos de lenguaje en escenarios de uso de herramientas sobre un conjunto masivo de APIs reales. Para el contexto de este trabajo, ToolLLM refuerza la idea de que una arquitectura modular debe diseñarse pensando en la extensibilidad, evitando acoplamientos fuertes entre el agente y cada herramienta concreta.

Junto a estas propuestas, también resulta necesario considerar trabajos centrados en su evaluación. En este sentido, Li et al. (Li y col., 2023) presentan API-Bank, un *benchmark* en el que se evalúan aspectos como la planificación, la recuperación de la API correcta y la ejecución de llamadas.

2.2.3. RAG

La técnica de *Retrieval-Augmented Generation* (RAG) surge como una respuesta a una de las limitaciones fundamentales de los modelos de lenguaje: su dependencia exclusiva del conocimiento almacenado en los parámetros del modelo. Aunque este conocimiento permite obtener un buen rendimiento en múltiples tareas, presenta problemas importantes cuando se requiere acceder a información específica o perteneciente a un dominio concreto.

En este contexto, Lewis et al. (Lewis y col., 2020) introducen RAG como un marco que combina un modelo generativo con una memoria externa, accesible mediante un mecanismo de recuperación. Su relevancia radica en que permite paliar las limitaciones de los modelos de lenguaje en dominios específicos al proporcionarles evidencia externa actualizada. No obstante, el uso de estos sistemas plantea retos significativos en el componente de recuperación: la búsqueda semántica simple a menudo presenta dificultades para capturar términos técnicos precisos, gestionar la ambigüedad de las consultas o garantizar que los documentos recuperados sean los más relevantes para la generación final. Afrontar estos retos justifica la necesidad de evolucionar el modelo hacia un componente de recuperación de información más robusto, que actúe como base sólida para la consulta y fundamentación de las respuestas.

La investigación posterior ha explorado distintas variantes orientadas a hacer el uso de RAG

más flexible y aplicable en sistemas reales. En esta línea, Shi et al. (Shi y col., 2024) proponen REPLUG, donde tratan al modelo de lenguaje como una caja negra y utilizan un recuperador ajustable cuyos documentos se añaden directamente al *prompt* del modelo. Demostraron que los beneficios de RAG no dependen necesariamente de modificar la arquitectura del modelo, sino que pueden alcanzarse mediante mecanismos externos de recuperación e integración de contexto.

Asai et al. (Asai y col., 2024) presentan Self-RAG, un enfoque en el que el modelo aprende no solo a recuperar información, sino también a reflexionar sobre la necesidad de dicha recuperación y a criticar la calidad de la respuesta generada. Esta contribución desplaza de la idea de un RAG estático hacia uno más adaptativo y autorreflexivo.

Jeong et al. (Jeong y col., 2024) proponen Adaptive-RAG, una arquitectura que selecciona dinámicamente la estrategia de recuperación más adecuada en función de la complejidad de la pregunta. De este modo, la literatura reciente sugiere que la calidad de un sistema RAG depende de la capacidad de decidir cómo y cuándo recuperar evidencia.

Una línea de investigación especialmente importante es la relacionada con la privacidad en sistemas RAG. En este sentido, Zeng et al. (Zeng y col., 2024) estudian cómo un sistema RAG puede exponer contenido de la base de recuperación y evidencian que el uso de información privada no solo aporta beneficios en términos de utilidad, sino que también exige nuevas medidas de protección. Refuerza el considerar la privacidad no como una característica accesorio, sino como una restricción de diseño de primer nivel.

2.2.4. Evaluación y mejora concreta del retrieval

Esta cuestión resulta especialmente relevante, ya que una de sus contribuciones previstas consiste precisamente en proponer y evaluar una mejora concreta sobre el componente de recuperación frente a un *baseline* inicial.

Un punto de partida fundamental en esta línea es el trabajo de Karpukhin et al. (Karpukhin y col., 2020) sobre *Dense Passage Retrieval* (DPR). DPR plantea aprender representaciones vectoriales en las que cada pregunta quede cerca de los documentos más relevantes, de manera que sea posible recuperarlos de forma eficiente incluso en grandes colecciones de documentos.

A partir de esta base, varios trabajos han abordado la optimización del entrenamiento de recuperadores densos. Entre ellos, Qu et al. (Qu y col., 2021) proponen RocketQA, que introduce mejoras específicas como la selección de negativos poco informativos o la existencia de falsos negativos en el entrenamiento. Esta aportación demuestra que una mejora del *retrieval*

no tiene por qué implicar rediseñar todo el pipeline, sino que puede consistir en una forma específica el entrenamiento o la selección de evidencia recuperada.

Nogueira et al. (Nogueira y col., 2020b) demuestran que un modelo generativo puede emplearse eficazmente para calcular relevancia documental y reordenar documentos previamente recuperados. Esta estrategia resulta atractiva porque permite aumentar la calidad del contexto recuperado sin comprometer excesivamente la arquitectura.

No obstante, mejorar el *retrieval* no es suficiente si no se dispone de criterios adecuados para medir su impacto. En este punto cobra especial relevancia el trabajo de Saad-Falcon et al. (Saad-Falcon y col., 2024) sobre ARES, el cual propone evaluar separadamente distintas dimensiones del sistema, como la relevancia del contexto recuperado y la relevancia global de la respuesta generada. En lugar de limitar la evaluación a métricas, refuerza la idea de que conviene analizar también la calidad del contexto recuperado.

2.2.5. Asistentes institucionales

Debido al contexto de este trabajo, interesa analizar propuestas que hayan abordado asistentes en contextos institucionales y trabajos que hayan explorado el uso de herramientas en lenguaje natural.

En el ámbito universitario, Trienes et al. (Trienes y col., 2025) presentan Marcel, un agente conversacional ligero y de código abierto orientado al soporte de estudiantes, su alcance permanece centrado en la respuesta a consultas de admisión. La solución combina un módulo de *Frequently Asked Questions* con un esquema de *Retrieval-Augmented Generation* para fundamentar las respuestas con información verificable.

Una propuesta más robusta en escenarios cerrados es URASys, de Nguyen et al. (Nguyen y col., 2025), que plantea un sistema unificado para responder preguntas estándar y ambiguas en tareas de *academic advising*. Es especialmente relevante porque muestra que, en contextos institucionales, no basta con recuperar información, sino que también es necesario manejar ambigüedad y reducir alucinaciones. No obstante, no aborda de forma central la integración de herramientas.

Más allá del entorno universitario, encontramos varias propuestas. Liu et al. (Liu y col., 2025) proponen WorkTeam, un marco multiagente para transformar instrucciones en lenguaje natural en flujos de trabajo estructurados en entornos empresariales. Su arquitectura se compone de tres agentes especializados: un supervisor que planifica, un orquestador que organiza componentes, y un agente *filler* que completa parámetros a partir de documentación relevante. Este trabajo transforma una instrucción textual a una acción compuesta sobre herramientas.

En una línea cercana al uso de herramientas, Zhang et al. (Zhang y col., 2025) presentan AskToAct. La idea central del trabajo consiste en utilizar los propios parámetros de las herramientas como representación explícita de la intención del usuario, generando automáticamente datos de entrenamiento a partir de consultas incompletas. Esta aportación refleja que, para ejecutar correctamente una herramienta, el sistema debe ser capaz de detectar qué información falta y solicitarla de manera adecuada.

Por último, Kalra et al. (Kalra y col., 2025) presentan HyPA-RAG, un sistema de *Retrieval-Augmented Generation* adaptativo para aplicaciones legales. La solución incorpora un clasificador de complejidad de la consulta para ajustar parámetros dinámicamente, una recuperación híbrida que combina métodos basados en grafos de conocimiento, y un marco de evaluación adaptado al dominio. Este trabajo es especialmente relevante para la parte investigadora, ya que demuestra que una mejora explícita del módulo de recuperación puede traducirse en ganancias en exactitud de recuperación, fidelidad y precisión contextual.

2.3. Encaje de la propuesta

La propuesta de este TFM se sitúa en la intersección entre asistentes institucionales especializados, sistemas de uso de herramientas y mejora experimental del componente de recuperación de información. Por una parte, se plantea un asistente institucional especializado orientado a resolver consultas sobre documentación interna. Por otra, incorpora una funcionalidad accionable: la generación y eventual envío supervisado de correos electrónicos como paso operativo posterior a la consulta. Finalmente incorpora una contribución experimental específica sobre el componente de recuperación de información basada en recuperación híbrida y *reranking*.

Nuestra propuesta busca cerrar el ciclo entre consulta y acción, transformando una respuesta fundamentada en una actuación útil y trazable.

Comparada con Marcel, nuestra propuesta comparte el interés por un asistente universitario basado en RAG, pero se diferencia en dos aspectos fundamentales. En primer lugar, el caso de uso no se restringe a admisión ni a orientación externa, sino que se orienta a soporte institucional sobre documentación y procedimientos internos. En segundo lugar, el sistema no se limita a responder preguntas, sino que incorpora una transición explícita desde la evidencia documental hacia una acción operativa, en este caso la redacción o envío supervisado de correos formales.

En relación con URASys, la propuesta coincide en la importancia de operar en entornos cerrados, reducir alucinaciones y tratar consultas difíciles. No obstante, mientras URASys con-

centra su aportación en la robustez del *question answering* frente a ambigüedad y no respondibles, este proyecto amplía el alcance hacia una arquitectura con capacidad de acción.

WorkTeam transforma instrucciones en *workflows* generales de negocio mediante una arquitectura multiagente de orquestación y relleno de parámetros. Esta propuesta, en cambio, parte de un escenario institucional centrado en la consulta documental y utiliza la acción como extensión natural de una respuesta fundamentada por RAG.

Finalmente, HyPA-RAG constituye el antecedente más cercano en la parte investigadora, ya que también propone mejorar el componente de recuperación de información mediante recuperación híbrida y ajuste adaptativo. No obstante, la diferencia principal es el contexto ya que HyPA-RAG se presenta como una solución especializada para consultas legales y de política pública.

Por tanto, la aportación diferencial radica en la combinación de elementos que, en los trabajos revisados, aparecen habitualmente por separado.

2.4. Conclusiones

La revisión realizada permite extraer varias conclusiones relevantes. En primer lugar, las aportaciones respaldan el diseño de una arquitectura modular con un agente orquestador que coordine herramientas y capacidades especializadas, especialmente cuando se busca extensibilidad, trazabilidad y control en entornos privados.

En segundo lugar, integrar herramientas de forma efectiva exige resolver cuestiones fundamentales: decidir cuándo es necesario recurrir a una capacidad externa, seleccionar la herramienta adecuada, construir correctamente la llamada y utilizar el resultado obtenido de manera coherente dentro del proceso de generación.

En tercer lugar, los trabajos revisados sobre *Retrieval-Augmented Generation* muestran que no siempre basta con recuperar información relevante, sino que también es necesario hacerlo mediante una arquitectura controlada y alineada con los requisitos de privacidad.

Asimismo, la literatura permite identificar varias estrategias principales para mejorar el componente de recuperación. Destacan los enfoques en varias etapas, donde una recuperación inicial eficiente se complementa con un *reranker* más preciso. La investigación reciente subraya que la evaluación del *retrieval* debe abordarse de forma explícita, considerando no solo cuántos documentos relevantes se recuperan, sino también cómo afecta dicha recuperación a la fidelidad y utilidad de la respuesta final. Por ello, este bloque del estado del arte proporciona una base directa para la parte experimental, justificando la comparación entre un *baseline* de recuperación semántica y una mejora concreta basada en recuperación híbrida y *reranking*.

En conjunto, los trabajos revisados muestran la existencia de asistentes especializados en dominios institucionales o cerrados, el interés creciente por la coordinación de herramientas, y la mejora del propio componente de recuperación de información como vía activa de investigación aplicada. Sin embargo, estas líneas suelen aparecer separadas y este vacío justifica el interés de una propuesta que combine consulta documental fundamentada, uso de herramientas orientadas a la acción y mejora experimental del componente de recuperación de información dentro de un mismo asistente institucional.

Capítulo 3

Objetivos y Metodología

En este capítulo, se presentarán los objetivos generales y específicos del trabajo, junto con los criterios definidos para comprobar su cumplimiento. Posteriormente, se describirá la metodología adoptada para el desarrollo del proyecto, así como la planificación prevista, los riesgos identificados y los recursos necesarios para su realización.

3.1. Objetivos Generales

El objetivo general es desarrollar y evaluar un asistente institucional, capaz de consultar documentación interna mediante un sistema *Retrieval-Augmented Generation* (RAG) y de apoyar acciones operativas mediante herramientas integradas, con el fin de mejorar su utilidad en un entorno controlado.

A mayores se persigue analizar en qué medida una mejora del componente de recuperación, basada en recuperación híbrida y *reranking*, produce un efecto observable sobre la calidad de la evidencia recuperada y de las respuestas generadas, en comparación con un *baseline* de recuperación semántica simple.

3.2. Objetivos Específicos

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

1. **Identificar** los requisitos funcionales y no funcionales de un asistente institucional privado, atendiendo a aspectos como consulta documental, fundamentación de respuestas, trazabilidad, control del flujo y uso supervisado de herramientas.
2. **Diseñar** una arquitectura modular basada en un agente orquestador que coordine la recuperación de información, la generación de respuestas y la invocación de herramientas

externas.

3. **Desarrollar** un prototipo funcional capaz de procesar consultas en lenguaje natural sobre documentación interna y generar respuestas apoyadas en evidencia recuperada.
4. **Integrar** una funcionalidad accionable basada en herramientas, centrada en la generación de correos electrónicos formales a partir de la información obtenida durante la consulta.
5. **Establecer** un *baseline* de recuperación basado en búsqueda semántica simple para disponer de una referencia inicial de funcionamiento.
6. **Implementar** una variante mejorada del componente de recuperación de información mediante una estrategia de recuperación híbrida y *reranking*.
7. **Definir** un conjunto de casos de prueba representativos del dominio institucional, incluyendo consultas informativas, consultas sobre procedimientos y consultas orientadas a acción.
8. **Comparar** el rendimiento del *baseline* y de la variante mejorada mediante métricas de recuperación, fundamentación de respuestas, utilidad de la salida generada y coste temporal del sistema.
9. **Evaluar** a través de métricas en qué medida la mejora introducida en el componente de recuperación repercute en la calidad global del asistente y en su capacidad para ofrecer respuestas útiles y operativamente aprovechables.
10. **Analizar** las fortalezas, limitaciones y posibles líneas de mejora de la solución propuesta en el contexto de asistentes institucionales privados y uso de herramientas.

3.3. Criterios de comprobación de los objetivos

Con el fin de que los objetivos anteriores puedan verificarse de forma objetiva, se emplearán los siguientes criterios de comprobación:

- El conjunto de evaluación deberá contener al menos 25 casos de prueba representativos del dominio.
- El prototipo deberá ser capaz de generar una respuesta para, al menos, el 90 % de los casos de prueba definidos.

- En los casos orientados a acción, el sistema deberá generar correos para, al menos, el 90 % de las consultas correspondientes.
- La comparación entre el *baseline* y la variante mejorada se realizará mediante métricas de recuperación como Recall@5 y MRR@5.
- Se considerará que la mejora propuesta produce un efecto observable si la variante mejorada obtiene, al menos, una mejora de 3 puntos porcentuales en Recall@5 o una mejora relativa del 5 % en MRR@5 respecto al *baseline*. En ambos casos, el valor @5 indica que la evaluación se realiza sobre los cinco primeros documentos recuperados por el sistema para cada consulta.
- Se considerará satisfactorio que al menos el 75 % de las respuestas generadas por la variante mejorada se apoyen de forma clara en los documentos recuperados.
- El coste temporal del sistema se medirá mediante la latencia media por consulta, procurando que la variante mejorada no incremente dicho tiempo en más de un 50 % respecto al *baseline*.

3.4. Metodología del trabajo

En el desarrollo de este se adoptará una metodología ágil basada en Scrum, al considerarse un enfoque adecuado para organizar un proyecto tecnológico con una parte aplicada y otra parte evaluativa. Esta elección se justifica por su flexibilidad, su carácter iterativo y su capacidad para adaptarse a cambios en los requisitos, en las decisiones de diseño o en los resultados obtenidos durante la implementación y la evaluación del sistema.

En este caso, el trabajo no consiste únicamente en desarrollar un prototipo funcional, sino también en analizar comparativamente el comportamiento de distintas configuraciones del componente de recuperación de información. Por ello, Scrum se empleará como marco de organización y seguimiento del desarrollo, permitiendo dividir el trabajo en incrementos manejables, revisar periódicamente el progreso y ajustar decisiones conforme avance el proyecto.

3.4.1. Scrum

Scrum es un marco de trabajo ágil orientado al desarrollo incremental de productos. Su funcionamiento se basa en iteraciones cortas y planificadas, denominadas *sprints*, al final de las cuales se obtiene un incremento funcional del sistema. Este enfoque resulta apropiado, ya que

permite avanzar de forma progresiva desde la definición del problema hasta la implementación del prototipo y su evaluación experimental.

3.4.2. Roles

Dado el contexto académico del trabajo, los roles de Scrum se adaptarán de forma simplificada:

- **Product Owner:** asumido por la dirección, al encargarse de supervisar el enfoque general del trabajo, validar su orientación y priorizar los elementos más relevantes del proyecto.
- **Scrum Master:** también asumido de forma parcial por la dirección, en la medida en que orienta el desarrollo, ayuda a resolver bloqueos y supervisa la coherencia metodológica del trabajo.
- **Equipo de desarrollo:** asumido por la estudiante, responsable del análisis, diseño, implementación, experimentación y redacción de la memoria.

3.4.3. Artefactos

Los principales artefactos de trabajo serán los siguientes:

- **Product Backlog:** listado priorizado de tareas y objetivos del proyecto, incluyendo decisiones de arquitectura, preparación documental, implementación de componentes, diseño de experimentos y redacción.
- **Sprint Backlog:** subconjunto de tareas seleccionadas para cada sprint.
- **Incremento:** resultado funcional o evaluable obtenido al final de cada sprint, como puede ser una primera arquitectura definida, un *baseline* operativo o una versión mejorada del sistema.

3.4.4. Eventos

El trabajo se organizará mediante los eventos habituales de Scrum, adaptados a un proyecto individual:

- **Sprint Planning:** definición de las tareas a abordar en cada iteración.
- **Seguimiento:** revisión periódica del progreso, dificultades encontradas y ajustes necesarios.

- **Sprint Review:** revisión del resultado obtenido al final de cada sprint.
- **Sprint Retrospective:** valoración de los aspectos que han funcionado correctamente y de los elementos a mejorar en la siguiente iteración.

3.4.5. Adaptación al proyecto

Aunque Scrum se concibe habitualmente para equipos de desarrollo, su estructura puede adaptarse a un trabajo individual. Los *sprints* no se orientarán únicamente a implementar funcionalidades, sino también a producir resultados parciales verificables.

De este modo, la metodología de desarrollo permitirá combinar dos dimensiones del trabajo: por una parte, la construcción iterativa del asistente institucional privado; por otra, la comparación entre un *baseline* de recuperación semántica y una variante mejorada basada en recuperación híbrida y *reranking*.

3.5. Riesgos y planes de contingencia

Durante el desarrollo resulta necesario identificar posibles riesgos técnicos, metodológicos y de planificación que puedan afectar al alcance, a la calidad de la solución o al calendario previsto. Dado que el proyecto combina implementación de un prototipo funcional con una evaluación experimental comparativa, la gestión de riesgos adquiere especial relevancia para asegurar la viabilidad del trabajo.

A continuación, se describen los principales riesgos identificados y las medidas de contingencia previstas para reducir su impacto:

1. **Dificultades en la integración de componentes heterogéneos.** La integración entre el modelo de lenguaje, el componente de recuperación, la base documental y la funcionalidad accionable puede presentar incompatibilidades técnicas o requerir más esfuerzo de implementación del previsto. Como plan de contingencia, se priorizará una arquitectura modular y desacoplada, permitiendo validar cada componente por separado antes de su integración completa.
2. **Calidad insuficiente de la base documental o del conjunto de evaluación.** El rendimiento del asistente depende en gran medida de la calidad del corpus documental y de la representatividad de los casos de prueba. Un conjunto poco adecuado podría dificultar tanto el funcionamiento del sistema como la evaluación de la mejora propuesta. Como

medida de contingencia, se realizará una selección y revisión temprana del corpus y de las consultas de prueba, garantizando que cubran los escenarios principales del dominio.

3. **Resultados experimentales poco concluyentes.** Existe la posibilidad de que la mejora basada en recuperación híbrida y *reranking* no produzca diferencias suficientemente claras respecto al *baseline*, o que dichas diferencias no sean tan amplias como se esperaba inicialmente. Como plan de contingencia, el trabajo no se orientará a demostrar una mejora absoluta, sino a realizar una comparación controlada y rigurosa entre ambas configuraciones.
4. **Incremento excesivo de la latencia del sistema.** La incorporación de una segunda etapa de recuperación o de un mecanismo de *reranking* puede aumentar el tiempo de respuesta del asistente y comprometer su utilidad práctica como prototipo. Para mitigar este riesgo, se medirá la latencia desde las primeras versiones funcionales y se limitará el número de documentos candidatos o el coste de los modelos auxiliares en caso necesario.
5. **Cambios en el alcance o en las decisiones técnicas durante el desarrollo.** Como sucede en muchos proyectos de desarrollo e investigación aplicada, algunas decisiones inicialmente previstas pueden necesitar ajustes conforme avance la implementación o la evaluación. Como medida de contingencia, se adoptará una planificación iterativa basada en Scrum, de forma que cada sprint permita revisar el estado del trabajo, reordenar prioridades y acotar el alcance sin perder coherencia con los objetivos definidos.
6. **Retrasos en el calendario previsto.** La simultaneidad entre implementación, experimentación y redacción de la memoria puede provocar desviaciones temporales respecto a la planificación inicial. Para reducir este riesgo, se organizará el trabajo en incrementos parciales y se reservará una fase final específica para revisión, análisis de resultados y redacción.
7. **Limitaciones derivadas del carácter individual del proyecto.** Al tratarse de un TFM desarrollado de forma individual, tanto el análisis como la implementación, la evaluación y la documentación recaen sobre una única persona, lo que puede ralentizar el avance en fases de mayor carga técnica. Como contingencia, se mantendrá una planificación realista, con objetivos acotados y verificables, evitando incorporar funcionalidades adicionales que no resulten imprescindibles para demostrar la contribución principal del trabajo.

3.6. Planificación del trabajo

De manera general, cada sprint tendrá una duración aproximada de entre dos y tres semanas, como se muestra en la Figura 1, aunque esta distribución podrá adaptarse en función de la complejidad real de las tareas y de las incidencias surgidas durante el desarrollo. Al final de cada iteración se realizará una revisión del avance conseguido y una replanificación de las tareas pendientes, con el fin de mantener el proyecto alineado con los objetivos establecidos.

3.6.1. Sprint 1: análisis y definición del problema

En esta primera fase se concretará el alcance del trabajo, se revisará el estado del arte ya recopilado y se terminarán de definir los requisitos funcionales y no funcionales del asistente institucional privado. Asimismo, se delimitará el caso de uso principal, se identificarán las capacidades mínimas del prototipo y se establecerán los criterios de evaluación que se utilizarán en la parte experimental.

Durante esta fase también se seleccionarán las herramientas y tecnologías necesarias para implementar el sistema, así como el enfoque general de la arquitectura.

3.6.2. Sprint 2: diseño de la arquitectura y preparación del entorno de trabajo

El primer sprint estará centrado en el diseño técnico del sistema. En esta etapa se definirá la arquitectura modular del asistente, identificando los componentes principales, sus responsabilidades y el flujo de interacción entre ellos. En particular, se detallará el papel del agente orquestador, el componente de recuperación documental, el modelo generativo y la funcionalidad de herramienta integrada.

Además, se preparará el entorno de desarrollo, se seleccionará o estructurará el corpus documental inicial y se organizará el material necesario para la construcción posterior del prototipo.

3.6.3. Sprint 3: implementación del *baseline* del asistente

En este sprint se desarrollará una primera versión funcional del sistema, que actuará como *baseline*. Esta configuración inicial permitirá procesar consultas en lenguaje natural, recuperar documentos relevantes mediante búsqueda semántica simple y generar respuestas apoyadas en la evidencia recuperada.

El objetivo de esta fase será disponer de una referencia operativa sobre la que poder comparar posteriormente la mejora investigadora del trabajo. Al finalizar este sprint deberá existir

una primera versión ejecutable del asistente, aunque todavía limitada a su funcionalidad esencial.

3.6.4. Sprint 4: integración de la funcionalidad accionable

Una vez disponible el *baseline*, el siguiente sprint se centrará en ampliar el sistema con una capacidad accionable. En concreto, se integrará la generación de borradores de correos electrónicos formales a partir de la consulta del usuario y de la información recuperada desde la base documental.

Esta fase permitirá que el asistente no solo responda preguntas, sino que también apoye una actuación posterior útil dentro del entorno institucional. Al finalizar este sprint, el prototipo deberá ser capaz de producir una salida operativa básica en los casos orientados a acción.

3.6.5. Sprint 5: implementación de la mejora del componente de recuperación de información

El cuarto sprint estará orientado a la principal aportación experimental del TFM. En esta etapa se implementará una variante mejorada del componente de recuperación de información basada en recuperación híbrida y *reranking*, manteniendo la posibilidad de compararla con el *baseline* definido anteriormente. El objetivo será introducir una mejora concreta y controlada sobre el proceso de recuperación documental, sin modificar de forma radical el resto del sistema.

3.6.6. Sprint 6: diseño de la evaluación y comparación experimental

En este sprint se preparará y ejecutará la evaluación comparativa entre el *baseline* y la variante mejorada. Para ello, se terminará de construir el conjunto de casos de prueba, se definirán las rúbricas de evaluación manual y se recogerán las métricas seleccionadas para el análisis.

La comparación se centrará en dimensiones como la calidad de la recuperación, la fundamentación de las respuestas, la utilidad de los borradores generados y el coste temporal del sistema. Esta fase permitirá disponer de resultados cuantitativos con los que analizar el impacto real de la mejora propuesta.

3.6.7. Sprint 7: Revisión final, análisis de resultados y redacción de la memoria

La última fase del trabajo se dedicará a consolidar los resultados obtenidos, interpretar los datos recogidos durante la evaluación y redactar la memoria final del TFM. También se revisará el grado de cumplimiento de los objetivos planteados y se identificarán las principales limitaciones del sistema, así como posibles líneas de mejora o ampliación futura. Esta etapa incluirá además la revisión formal de la memoria.



Figura 1: Diagrama de Gantt con la planificación temporal del trabajo.

3.7. Recursos y costes

En esta sección se describen los recursos necesarios y se realiza una estimación orientativa de sus costes. Dado que se trata de un proyecto académico desarrollado de forma individual, la mayor parte del esfuerzo recae en la estudiante, mientras que la dirección del TFM asume funciones de supervisión, revisión y seguimiento.

3.7.1. Recursos humanos

Los recursos humanos considerados para el desarrollo del proyecto son los siguientes:

- **Dirección del TFM:** responsable de orientar el trabajo, revisar su evolución, validar las decisiones principales y supervisar la coherencia metodológica y académica del proyecto.
- **Estudiante:** responsable del análisis del problema, diseño de la arquitectura, implementación del prototipo, preparación del conjunto de evaluación, ejecución de los experimentos, análisis de resultados y redacción de la memoria final.

Aunque el proyecto es realizado por una única persona, desde el punto de vista de la estimación puede considerarse que la estudiante asume varias funciones de forma simultánea, entre ellas las de analista, desarrolladora e investigadora aplicada.

3.7.2. Recursos técnicos

Para el desarrollo del TFM se requerirán los siguientes recursos técnicos:

- Ordenador personal para desarrollo, pruebas y redacción de la memoria.
- Entorno de programación y herramientas de desarrollo para la implementación del prototipo.
- Herramientas de edición y documentación para la elaboración de diagramas, esquemas y memoria.
- Servicios o librerías necesarios para la implementación del sistema RAG, la integración del modelo generativo y el procesamiento documental.
- Herramientas de evaluación y análisis de resultados.

En términos generales, se priorizará el uso de herramientas gratuitas, académicas o ya disponibles en el entorno de trabajo, por lo que no se prevé un coste material elevado asociado al proyecto. En caso de utilizar servicios externos de pago, estos quedarán limitados a un uso puntual o experimental.

3.7.3. Estimación de dedicación

La siguiente tabla recoge una estimación orientativa de las horas de trabajo necesarias para desarrollar el proyecto:

Rol	Horas proyecto	Horas memoria	Total horas
Estudiante	300	120	420
Dirección del TFM	20	10	30

Tabla 1: Estimación de horas dedicadas al proyecto.

La dedicación principal corresponde a la estudiante, ya que asume tanto el desarrollo técnico del prototipo como la parte experimental y documental del trabajo. En cambio, la dirección del TFM participa de manera periódica mediante reuniones de seguimiento, revisión de avances y supervisión de la memoria.

3.7.4. Estimación de costes

A efectos de estimación, se asigna un coste por hora orientativo a cada uno de los roles considerados. Estos valores no deben interpretarse como costes contractuales reales, sino como una aproximación académica al esfuerzo invertido en el proyecto.

Rol	Total horas	Coste/hora (€)	Coste total (€)
Estudiante	420	25	10.500
Dirección del TFM	30	35	1.050
Total	450	–	11.550

Tabla 2: Estimación orientativa de costes humanos del proyecto.

Por tanto, el coste total estimado del proyecto, considerando únicamente los recursos humanos, sería de 11.550€. Esta cifra representa una valoración aproximada del esfuerzo necesario para desarrollar el asistente, implementar la mejora experimental propuesta y documentar adecuadamente el trabajo realizado.

Capítulo 4

Fundamentos tecnológicos

Este capítulo describe las decisiones tecnológicas adoptadas para el prototipo del asistente institucional. Se presentan las herramientas principales de desarrollo, las librerías clave del pipeline RAG y los criterios que han guiado la selección frente a alternativas viables.

4.1. Tecnologías de desarrollo

Esta sección recoge las tecnologías utilizadas como base del desarrollo y de la operación local del sistema. La prioridad ha sido contar con un entorno reproducible, de bajo coste y compatible con un enfoque local-first, sin renunciar a opciones escalables en etapas posteriores.

4.1.1. Python

El lenguaje principal del proyecto es Python. Esta elección se justifica por la madurez de su ecosistema en NLP, su amplia compatibilidad con librerías de embeddings y extirreranking, y su facilidad para integrar APIs y herramientas externas. Frente a alternativas como Java o Go, Python reduce el tiempo de desarrollo y facilita la experimentación rápida, aspecto clave en un trabajo con componente evaluativo.

Además, el uso de entornos virtuales permite aislar dependencias y mantener un control claro sobre la reproducibilidad del prototipo. Aunque lenguajes como C++ podrían aportar mejoras de rendimiento, el coste de integración y la complejidad no compensan en esta fase, dado que el cuello de botella suele residir en los modelos y no en la lógica de orquestación.

4.1.2. UI: Streamlit como opción preferente

Para la interfaz conversacional se prioriza Streamlit, ya que permite prototipar con rapidez y mantener la capa de UI fuera del foco principal del trabajo. Se consideraron Chainlit y Gradio; sin

embargo, la simplicidad de Streamlit y su adopción previa en proyectos similares lo convierten en una opción práctica para iterar sin fricción.

La interfaz se mantiene desacoplada del pipeline RAG para permitir sustituciones futuras si fuera necesario, sin afectar a la lógica de recuperación ni al orquestador.

4.1.3. Qdrant

Para el almacenamiento vectorial se eligió Qdrant. Frente a FAISS, que es una librería local sin servidor ni API persistente, Qdrant ofrece un motor vectorial completo con persistencia, filtrado por metadatos y soporte para búsqueda híbrida. En comparación con Chroma, Qdrant proporciona mayor estabilidad operativa y opciones de despliegue más cercanas a un entorno productivo.

También se valoraron soluciones gestionadas como Pinecone o Weaviate. Sin embargo, Qdrant permite operar localmente sin costes adicionales, lo que se ajusta al requisito de privacidad y al enfoque local-first del prototipo. Esta decisión mantiene abierta la posibilidad de migrar a un servicio gestionado si el proyecto evoluciona a un entorno con mayores requisitos de escalabilidad.

4.2. Librerías utilizadas

En esta sección se detallan las librerías clave que implementan el núcleo del pipeline RAG. Cada elección se ha realizado tras comparar alternativas que podrían aportar ventajas similares en rendimiento o facilidad de uso.

4.2.1. Embeddings: BGE-M3

Para la representación vectorial se ha seleccionado BGE-M3. Esta familia de modelos destaca por su rendimiento en recuperación multilingüe, su capacidad para manejar distintos tipos de consulta y su compatibilidad con entornos locales. Se comparó con alternativas como E5, modelos SBERT clásicos y embeddings gestionados vía API (por ejemplo, OpenAI).

La elección de BGE-M3 responde a un equilibrio entre calidad y control. Frente a servicios externos, permite operar con privacidad total y sin costes por uso. Frente a modelos más antiguos, ofrece mejores resultados en tareas de recuperación heterogénea y mayor robustez en dominios específicos.

4.2.2. LLM: vLLM con modelo local cuantizado

Para la inferencia del modelo generativo se opta por vLLM con un modelo local pequeño y cuantizado, lo que permite iterar rápido con un pipeline funcional y mantener el control del entorno. Esta elección prioriza la velocidad de pruebas y la reproducibilidad, manteniendo el enfoque local-first del prototipo.

Se mantiene abierta la posibilidad de escalar a modelos mayores mediante APIs externas si el hardware disponible resulta insuficiente o si la evaluación requiere mayor calidad. No obstante, durante las primeras iteraciones el objetivo es validar el flujo completo con un coste computacional reducido.

4.2.3. Reranking: BGE Reranker

Para la segunda etapa de recuperación se seleccionó el extitbge-reranker-v2-m3. Se evaluaron alternativas como extitcross-encoders genéricos o modelos de extitreranking más ligeros, pero la familia BGE ofrece una buena relación entre calidad y coste computacional, además de mantener coherencia con los embeddings elegidos.

Esta decisión permite introducir una mejora controlada sobre el extitbaseline de recuperación semántica simple, sin rediseñar el pipeline completo. Además, facilita la comparación experimental, ya que se trata de un cambio focalizado y medible.

4.3. Funcionalidad accionable

4.3.1. Correos mockeados

La funcionalidad de generación de correos se mantiene mockeada en esta fase inicial. Esta decisión permite probar el flujo conversacional y la integración de herramientas sin depender de servicios externos ni de configuraciones de envío reales. El objetivo es validar el comportamiento y la utilidad del borrador generado antes de implementar la integración definitiva.

4.4. Procesamiento documental e ingesta

Además del núcleo RAG, el prototipo requiere un flujo de ingesta capaz de manejar formatos heterogéneos. Para PDFs se utiliza PyMuPDF, elegido frente a alternativas como pdfplumber por su velocidad y estabilidad en documentos extensos. Para formatos ofimáticos (DOCX,

PPTX, HTML), se utiliza Pandoc, que proporciona conversiones robustas a Markdown y simplifica la homogenización del corpus.

Esta combinación reduce la dependencia de herramientas específicas por formato y permite aplicar un esquema de chunking consistente. Se priorizó un flujo reproducible y automatizable, ya que la calidad de la ingesta impacta directamente en la evaluación del componente de recuperación.

Capítulo 5

Conclusiones y trabajo futuro

Este último bloque (habitualmente un capítulo; en ocasiones, dos capítulos complementarios) es habitual en todos los tipos de trabajos y presenta el resumen final de tu trabajo y debe servir para informar del alcance y relevancia de tu aportación.

Suele estructurarse empezando con un resumen del problema tratado, de cómo se ha abordado y de por qué la solución sería válida. Es recomendable que incluya también un resumen de las contribuciones del trabajo, en el que relaciones las contribuciones y los resultados obtenidos con los objetivos que habías planteado para el trabajo, discutiendo hasta qué punto has conseguido resolver los objetivos planteados.

Finalmente, se suele dedicar una última sección a hablar de líneas de trabajo futuro que podrían aportar valor añadido al TFM realizado. La sección debería señalar las perspectivas de futuro que abre el trabajo desarrollado para el campo de estudio definido. En el fondo, debes justificar de qué modo puede emplearse la aportación que has desarrollado y en qué campos.

Bibliografía

- Karpukhin, Vladimir y col. (2020). «Dense Passage Retrieval for Open-Domain Question Answering». En: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Online: Association for Computational Linguistics, págs. 6769-6781. doi: [10.18653/v1/2020.emnlp-main.550](https://doi.org/10.18653/v1/2020.emnlp-main.550).
- Lewis, Patrick y col. (2020). «Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks». En: *Advances in Neural Information Processing Systems*.
- Nogueira, Rodrigo y col. (2020a). «Document Ranking with a Pretrained Sequence-to-Sequence Model». En: *Findings of the Association for Computational Linguistics: EMNLP 2020*. Online: Association for Computational Linguistics, págs. 708-718. doi: [10.18653/v1/2020.findings-emnlp.63](https://doi.org/10.18653/v1/2020.findings-emnlp.63). url: <https://aclanthology.org/2020.findings-emnlp.63/>.
- (2020b). «Document Ranking with a Pretrained Sequence-to-Sequence Model». En: *Findings of the Association for Computational Linguistics: EMNLP 2020*. Online: Association for Computational Linguistics, págs. 708-718. doi: [10.18653/v1/2020.findings-emnlp.63](https://doi.org/10.18653/v1/2020.findings-emnlp.63).
- Qu, Yingqi y col. (2021). «RocketQA: An Optimized Training Approach to Dense Passage Retrieval for Open-Domain Question Answering». En: *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Online: Association for Computational Linguistics, págs. 5835-5847. doi: [10.18653/v1/2021.naacl-main.466](https://doi.org/10.18653/v1/2021.naacl-main.466).
- Li, Minghao y col. (2023). «API-Bank: A Comprehensive Benchmark for Tool-Augmented LLMs». En: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Singapore: Association for Computational Linguistics, págs. 3102-3116. doi: [10.18653/v1/2023.emnlp-main.187](https://doi.org/10.18653/v1/2023.emnlp-main.187).
- Schick, Timo y col. (2023). «Toolformer: Language Models Can Teach Themselves to Use Tools». En: *Advances in Neural Information Processing Systems*.
- Yao, Shunyu y col. (2023). «ReAct: Synergizing Reasoning and Acting in Language Models». En: *The Eleventh International Conference on Learning Representations*.

- Asai, Akari y col. (2024). «Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection». En: *The Twelfth International Conference on Learning Representations*.
- Chen, Weize y col. (2024). «AgentVerse: Facilitating Multi-Agent Collaboration and Exploring Emergent Behaviors». En: *The Twelfth International Conference on Learning Representations*.
- Hong, Sirui y col. (2024). «MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework». En: *The Twelfth International Conference on Learning Representations*.
- Jeong, Soyeong y col. (2024). «Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity». En: *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, págs. 7036-7050. doi: [10.18653/v1/2024.naacl-long.389](https://doi.org/10.18653/v1/2024.naacl-long.389).
- Patil, Shishir G. y col. (2024). «Gorilla: Large Language Model Connected with Massive APIs». En: *Advances in Neural Information Processing Systems*. doi: [10.52202/079017-4020](https://doi.org/10.52202/079017-4020).
- Qin, Yujia y col. (2024). «ToolLLM: Facilitating Large Language Models to Master 16000+ Real-world APIs». En: *The Twelfth International Conference on Learning Representations*.
- Saad-Falcon, Jon y col. (2024). «ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems». En: *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*. Mexico City, Mexico: Association for Computational Linguistics, págs. 338-354. doi: [10.18653/v1/2024.naacl-long.20](https://doi.org/10.18653/v1/2024.naacl-long.20).
- Shi, Weijia y col. (2024). «REPLUG: Retrieval-Augmented Black-Box Language Models». En: *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, págs. 8371-8384. doi: [10.18653/v1/2024.naacl-long.463](https://doi.org/10.18653/v1/2024.naacl-long.463).
- Wu, Qingyun y col. (2024). «AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversations». En: *Proceedings of the First Conference on Language Modeling*.
- Zeng, Shenglai y col. (2024). «The Good and The Bad: Exploring Privacy Issues in Retrieval-Augmented Generation (RAG)». En: *Findings of the Association for Computational Linguistics: ACL 2024*, págs. 4505-4524. doi: [10.18653/v1/2024.findings-acl.267](https://doi.org/10.18653/v1/2024.findings-acl.267).
- Dang, Yufan y col. (2025). «Multi-Agent Collaboration via Evolving Orchestration». En: *Advances in Neural Information Processing Systems*.
- Kalra, Rishi y col. (abr. de 2025). «HyPA-RAG: A Hybrid Parameter Adaptive Retrieval-Augmented Generation System for AI Legal and Policy Applications». En: *Proceedings of the 2025*

- Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 3: Industry Track)*. Albuquerque, New Mexico: Association for Computational Linguistics, págs. 1036-1054. doi: [10.18653/v1/2025.naacl-industry.79](https://doi.org/10.18653/v1/2025.naacl-industry.79).
- Liu, Hanchao y col. (abr. de 2025). «WorkTeam: Constructing Workflows from Natural Language with Multi-Agents». En: *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 3: Industry Track)*. Albuquerque, New Mexico: Association for Computational Linguistics, págs. 20-35. doi: [10.18653/v1/2025.naacl-industry.3](https://doi.org/10.18653/v1/2025.naacl-industry.3).
- Nguyen, Long S. T. y col. (dic. de 2025). «When in Doubt, Ask First: A Unified Retrieval Agent-Based System for Ambiguous and Unanswerable Question Answering». En: *Proceedings of the 14th International Joint Conference on Natural Language Processing and the 4th Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics*. Mumbai, India: The Asian Federation of Natural Language Processing y The Association for Computational Linguistics, págs. 452-472. doi: [10.18653/v1/2025.findings-ijcnlp.27](https://doi.org/10.18653/v1/2025.findings-ijcnlp.27).
- Trienes, Jan y col. (2025). «Marcel: A Lightweight and Open-Source Conversational Agent for University Student Support». En: *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Suzhou, China: Association for Computational Linguistics, págs. 181-195. url: <https://aclanthology.org/2025.emnlp-demos.13/>.
- Zhang, Xuan y col. (nov. de 2025). «AskToAct: Enhancing LLMs Tool Use via Self-Correcting Clarification». En: *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*. Suzhou, China: Association for Computational Linguistics, págs. 13484-13511. doi: [10.18653/v1/2025.emnlp-main.682](https://doi.org/10.18653/v1/2025.emnlp-main.682).

Apéndices

Apéndice A

Fusce viverra lectus

Nam viverra, odio et vulputate ultricies, sem libero ornare nunc, nec suscipit urna sapien eu sapien. Nulla erat nulla, hendrerit non elit vitae, venenatis malesuada libero. Duis ornare sapien sed lacus condimentum rutrum. Donec feugiat erat id elit aliquam, a ultrices lectus mattis. In vitae nisl tortor. Proin pellentesque nec odio et posuere. Ut aliquet quam ac magna tincidunt ultrices. Nullam sit amet elementum leo. Pellentesque vitae mi dolor. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Suspendisse tincidunt mi arcu, vitae porttitor mauris elementum ut.

In vel condimentum diam. Fusce viverra lectus sed ultrices tristique. Sed euismod sem tincidunt porttitor mollis. Aenean venenatis sem eros, vel ultrices lectus euismod ac. Nam molestie ex vitae volutpat porta. Proin eu turpis ut ipsum rhoncus ultricies nec eu lectus. Cras malesuada fringilla rutrum. In posuere, lectus fermentum molestie mattis, metus ligula ullamcorper sapien, id elementum nulla odio eget odio. Aenean risus velit, pretium at egestas mattis, aliquet scelerisque massa. Vivamus in mi sed mauris mollis fringilla quis quis ante.